

법률 도메인 LLM 답변에 대한 3단계 환각 탐지 모델

A Three-Stage Hallucination Detection Model for LLM Answers in the Legal Domain

요약

대규모 언어모델(LLM)의 환각(hallucination)은 정확성이 필수적인 법률 상담 도메인에서 심각한 법적·경제적 피해를 유발할 수 있다. 본 논문은 법률 도메인 LLM 답변을 위한 3단계 환각 탐지 모델을 제안한다. 제안 모델은 유사 질문 기반 일관성 검사, 개체명 인식(NER) 기반 법률 개체 검증, 자연어 추론(NLI) 기반 모순 검사를 각각 독립적으로 수행하고 OR 규칙으로 결합하여 환각 누락을 최소화한다. 정상 400개와 환각 400개로 구성된 800개 평가셋 실험에서 제안 모델은 Recall 0.998, F1 0.668을 달성하여 SelfCheckGPT(F1 0.659) 대비 우수한 성능을 보였으며, 법률 도메인에서 요구되는 높은 안전성을 확보하였다.

1. 서론

대규모 언어모델(Large Language Model, LLM)은 자연어 질의응답과 문서 요약 등 다양한 과제에서 뛰어난 성능을 보이고 있다. 그러나 LLM은 학습한 사실과 다른 내용을 자연스러운 문장으로 생성하는 환각(hallucination) 문제를 안고 있다. 환각은 생성된 텍스트가 입력이나 사실적 근거와 일치하지 않는 현상을 의미하며, 모델의 규모를 키우거나 학습 데이터를 늘려도 완전히 해소되지 않는 구조적 한계로 알려져 있다[1].

환각의 위험은 도메인에 따라 그 심각성이 크게 달라진다. 일반적인 대화나 창작에서는 환각이 사용자 경험을 저해하는 수준에 그치지만, 정확성이 핵심 가치인 전문 도메인에서는 직접적인 피해로 이어질 수 있다. 특히 법률 도메인은 환각의 위험이 가장 큰 분야 중 하나이다. 법률 상담 LLM이 존재하지 않는 조문번호를 제시하거나 형량을 잘못 안내하고, 부정확한 기관 정보를 답변에 포함하면 이용자는 잘못된 법적 판단을 내릴 수 있으며, 이는 곧 법적·경제적 손실로 직결된다.

법률 텍스트는 법령명, 조문번호, 형량, 기관명과 같이 한 글자 또는 한 자리 숫자만 달라져도 의미가 완전히 바뀌는 개체를 다수 포함한다. 예를 들어 '제43조'와 '제34조'는 전혀 다른 규정을 가리키며, '3년 이하 징역'과 '30년 이하 징역'은 상이한 법적 효과를 가진다. 따라서 법률 도메인의 환각 탐지는 일반 도메인보다 훨씬 높은 정밀도와 민감도를 요구하며, 특히 환각을 놓치지 않는 능력이 중요하다[2].

본 논문은 법률 도메인 LLM 답변에 특화된 3단계 환각 탐

지 모델을 제안한다. 제안 모델은 (1) 유사 질문에 대한 답변의 일관성을 검사하는 단계, (2) 법률 개체명을 추출하여 근거 문서와 대조하는 NER 단계, (3) 답변과 근거 문서 간 의미적 모순을 검사하는 NLI 단계로 구성되며, 세 단계의 판정을 OR 규칙으로 결합한다. 법률 상담에서는 환각을 정상으로 잘못 판정하는 미탐(false negative)의 비용이 정상을 환각으로 잘못 판정하는 오탐(false positive)의 비용보다 훨씬 크다. 이에 본 연구는 재현율(Recall) 극대화를 핵심 전략으로 삼는다.

본 논문의 주요 기여는 다음 세 가지이다. 첫째, 서로 다른 탐지 원리를 가진 세 가지 검증 단계를 결합한 3단계 Hybrid 환각 탐지 모델을 제안한다. 둘째, 정상 400개와 환각 400개로 구성된 800개 법률 도메인 평가셋을 통해 제안 모델을 정량적으로 검증한다. 셋째, 제안 모델이 기존 일관성 기반 방법인 SelfCheckGPT 대비 더 높은 재현율과 F1 점수를 달성함을 실험으로 입증한다.

2. 관련 연구

2.1 LLM의 환각 문제

"Survey of Hallucination in Natural Language Generation"[1]은 자연어 생성에서의 환각을 입력 정보와 모순되는 내재적(intrinsic) 환각과 입력으로 검증할 수 없는 외재적(extrinsic) 환각으로 분류하고, 요약·대화·질의응답 등 과제별 환각 양상과 다양한 완화 기법을 체계적으로 정리하였다. 이 연구는 환각이 학습 데이터의 편향, 디코딩 과정의 불확실성, 지식의 부재 등 복합적 원인에서 비롯된다고 분석하였다.

2.2 환각 탐지 방법

SelfCheckGPT[3]는 외부 지식 베이스 없이 환각을 탐지하는 대표적인 방법이다. 동일한 질문에 대해 여러 개의 샘플 답변을 확률적으로 생성한 뒤, 답변 간 일관성이 낮으면 해당 내용을 환각으로 판정한다. 이는 모델이 충분히 학습한 사실은 샘플마다 일관되게 생성되지만, 환각된 내용은 샘플마다 달라진다는 직관에 기반한다. SelfCheckGPT는 모델 내부 정보에 접근할 수 없는 블랙박스 LLM에도 적용 가능하다는 장점이 있으나, 일관성만으로는 모든 샘플에서 반복되는 사실 오류를 포착하기 어렵다는 한계가 있다.

2.3 사실 검증과 검색 증강 생성

사실 검증(fact verification)은 주어진 주장을 근거 문서와 대조하여 진위를 판별하는 과제이다. “FEVER: a Large-scale Dataset for Fact Extraction and VERification”[4]은 18만여 개의 주장으로 구성된 대규모 사실 검증 데이터셋으로, 주장을 SUPPORTED, REFUTED, NOTENOUGHINFO의 세 범주로 분류하고 근거 문장을 함께 제시하는 파이프라인을 제안하였다. 한편 “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”[5]에서 제안한 검색 증강 생성(Retrieval-Augmented Generation, RAG)은 외부 문서를 검색하여 생성 과정에 활용함으로써 환각을 완화한다. 그러나 검색된 문서가 부정확하거나 모델이 이를 잘못 활용하면 RAG 환경에서도 환각이 발생할 수 있다.

2.4 법률 도메인 자연어처리

법률 도메인은 전문 용어와 고유한 문체로 인해 일반 언어모델의 성능이 저하되는 분야이다. “LEGAL-BERT: The Muppets straight out of Law School”[2]은 법률 말뭉치로 사전학습한 도메인 특화 모델을 제안하여, 도메인 특화 사전 학습이 법률 문서 분류, 개체명 인식 등 하위 과제의 성능을 향상시킴을 보였다. 이는 법률 도메인의 특수성이 별도의 모델링을 요구함을 시사한다.

2.5 기존 연구의 한계

기존 환각 탐지 연구는 주로 일반 도메인을 대상으로 하며, 법률 도메인 특유의 개체인 법령명, 조문번호, 형량에 대한 정밀 검증은 충분히 다루지 못하였다. 또한 단일 탐지 원리에 의존하는 방법은 특정 유형의 환각에는 강하지만 다른 유형은 놓치는 경향이 있다. 본 연구는 일관성 검사, 개체명 검증, 모순 검사라는 상호 보완적 원리를 결합하여 이러한 한계를 보완하고, 법률 도메인에 특화된 탐지 모델을 구성한다.

3. 제안 방법

3.1 전체 구조

제안 모델은 법률 상담 LLM이 생성한 답변을 입력으로 받아, 세 가지 독립적 검증 단계를 거쳐 환각 여부를 판정한다. 그림 1은 제안 모델의 전체 구조를 나타낸다. 세 단계는 각각 서로 다른 탐지 원리에 기반하므로 상호 보완적이며, 어느 한 단계라도 환각을 탐지하면 최종적으로 환각으로 판정하는 OR 결합 규칙을 적용한다. 이러한 설계는 개별 단계의 미탐을 다른 단계가 보완하도록 하여 전체 재현율을 높인다.




그림 1. 제안하는 3단계 환각 탐지 모델의 전체 구조

3.2 STEP 1: 일관성 검사

첫 번째 단계는 답변의 일관성을 검사한다. 원본 질문과 의미가 유사한 질문 10개를 LLM으로 생성하고, 원본을 포함한 11개 질문 각각에 대한 답변을 생성한다. 이후 원본 답변과 나머지 답변들 사이의 일관성 점수를, 답변 간 의미 유사도(BERTScore[6] 기반, 70%)와 법조항·금액 등 핵심 정보의 일치 여부(30%)를 가중 합산하여 산출한다. BERTScore는 사전학습 언어모델의 문맥 임베딩을 이용해 의미 유사도를 정밀하게 계산하는 지표이다. 모델이 충분히 학습한 사실은 질문이 달라져도 답변이 일관되지만, 환각된 내용은 답변마다 달라져 일관성 점수가 낮아진다. 일관성 점수가 임계값보다 낮으면 환각으로 판정한다.

3.3 STEP 2: NER 개체명 검증

두 번째 단계는 답변에서 법률 개체명을 추출하여 근거 문서와 대조한다. 추출 대상은 법령명·조항번호(LAW), 범죄명(CRIME), 기관명(ORG), 금액(AMOUNT), 형량(PENALTY), 날짜(DATE)의 6종 개체이다. 답변과 RAG 근거 문서 양쪽에서 동일하게 개체를 추출한 뒤 1:1로 대조하여, 근거와 일치하지 않는 개체가 발견되면 해당 답변을 환각으로 판정한다. 예를 들어 답변이 ‘제45조’를 제시했으나 근거 문서가 ‘제43

조'를 담고 있으면 불일치로 간주한다. 이 단계는 조항번호 오류나 형량 왜곡과 같이 일관성 검사만으로는 놓치기 쉬운 명시적 사실 오류를 직접적으로 포착한다.

3.4 STEP 3: NLI 모순 검사

세 번째 단계는 답변과 근거 문서 간의 의미적 모순을 검사한다. 법령·형량·금액 등 핵심 정보를 포함한 답변 문장만을 대상으로, 해당 문장과 RAG 근거 문서를 1:1로 자연어 추론(Natural Language Inference, NLI) 모델에 입력한다. XNLI[7]로 학습된 mDeBERTa[8] 모델을 사용하여 두 문장 사이의 모순(contradiction) 점수를 산출하며, mDeBERTa는 분리된 어텐션(disentangled attention) 구조로 문장 간 의미 관계를 정밀하게 추론한다. 모순 점수가 0.70 이상이면 답변이 근거와 충돌하는 것으로 보아 환각으로 판정한다. 예컨대 근거가 '임금은 매월 1회 이상 지급해야 한다'인데 답변이 '임금은 분기별로 지급해도 된다'라면 모순 점수가 높게 나타난다.

3.5 OR 결합 전략

세 단계는 각각 독립적으로 환각 여부를 출력하며, 셋 중 하나라도 환각으로 판정하면 최종 판정은 환각이 된다. 이러한 OR 결합은 각 단계가 포착하는 환각 유형이 서로 다르다는 점을 활용한다. 일관성 검사는 모델이 확신하지 못하는 내용을, 개체명 검증은 명시적 사실 오류를, 모순 검사는 근거와의 논리적 충돌을 각각 담당한다. 결과적으로 단일 방법보다 폭넓은 환각을 포착할 수 있다. 이는 법률 상담에서 환각 미탐(위험)이 정상 오탐(안전)보다 훨씬 치명적이라는 도메인 특성을 반영한 설계 선택이다.

4. 실험 및 결과

4.1 평가 데이터셋

표 1. 평가셋의 환각 유형 구성

환각 유형	설명 및 예시
조항번호 오류	존재하지 않는 조문번호 생성
연락처/기관명 오류	잘못된 기관명·연락처 제시
무관 법령 주입	질의와 무관한 법령 인용
의미 왜곡	수치·의미 왜곡

평가셋은 정상 답변 400개와 환각 답변 400개로 구성된 총 800개의 법률 상담 답변이다. 환각 답변은 실제 발생 가능한 오류 양상을 반영하여 네 가지 유형으로 각 100개씩 생

성하였다. 표 1은 네 가지 환각 유형과 그 예시를 정리한 것이다. 각 유형은 법률 답변에서 빈번하게 나타나는 오류 패턴을 모사하며, 이를 통해 제안 모델이 다양한 환각을 균형 있게 탐지하는지 평가할 수 있다.

정상 답변 400개는 지식 베이스의 근거와 일치하는 정확한 법률 정보를 담고 있어, 모델의 오탐 경향을 함께 측정할 수 있도록 설계되었다.

4.2 비교 모델 및 평가 지표

비교 모델로는 일관성 기반의 SelfCheckGPT-NLI와 메타 모픽 관계 기반의 MetaQA[9]를 사용하였다. SelfCheckGPT-NLI는 샘플 답변 간의 NLI 관계로 일관성을 측정하고, MetaQA는 답변에서 사실을 추출하여 외부 지식과 검증한다. 평가 지표로는 Precision, Recall, F1-Score, Accuracy를 사용하였다. Precision은 환각으로 판정한 것 중 실제 환각의 비율을, Recall은 실제 환각 중 탐지한 비율을 의미한다. 법률 도메인에서는 환각을 놓치지 않는 것이 중요하므로 Recall을 가장 중요한 지표로 본다.

4.3 구현 환경

법률 지식 베이스는 법령 5,056개, 판례 57,422개, 매뉴얼 8,132개의 청크(chunk)로 구성되어 총 70,610개의 청크를 포함한다. 답변 생성과 유사 질문 생성에는 GPT-4o-mini를, NLI 모순 검사에는 XNLI로 학습된 mDeBERTa-xnli 모델을 사용하였다. 일관성 검사는 의미 유사도와 핵심 정보 일치 여부를 7:3으로 가중 합산하며, NLI 모순 임계값은 0.70으로 설정하였다.

4.4 실험 결과

표 2는 세 모델의 환각 탐지 성능을 비교한 결과이다. 제안 모델은 Recall 0.998을 달성하여 환각 400개 중 399개를 탐지하였으며, 단 1개만을 놓쳤다. F1 점수는 0.668로 일관성 기반의 SelfCheckGPT-NLI(0.659)를 상회하였다. 그림 2는 지표별 성능을 시각적으로 비교한 것으로, 제안 모델이 Recall 측면에서 다른 두 모델을 뚜렷하게 앞서는 것을 확인할 수 있다.

표 2. 환각 탐지 성능 비교

모델	Prec.	Recall	F1	Acc.
제안 모델	0.502	0.998	0.668	0.504
SelfCheckGPT-NLI	0.517	0.910	0.659	0.530
MetaQA	0.775	0.793	0.784	0.784




그림 2. 모델별 환각 탐지 성능 비교

4.5 결과 분석 및 논의

제안 모델의 가장 큰 강점은 Recall 0.998로, 법률 도메인에서 요구되는 높은 안전성을 충족한다는 점이다. 환각 400개 중 399개를 탐지하여 미탐을 1개로 최소화하였으며, 이는 잘못된 법률 정보가 이용자에게 전달될 위험을 거의 제거함을 의미한다.

반면 제안 모델의 Precision은 0.502로, 정상 답변 중 상당수를 환각으로 오탐하는 보수적 판정 경향을 보였다. 이는 OR 결합과 보수적 판정 기준으로 인해 세 단계 중 하나라도 의심 신호를 보이면 환각으로 판정하기 때문이다. 그러나 법률 상담에서는 잘못된 정보를 제공하는 위험이, 안전한 답변을 한 번 더 검토하게 만드는 비용보다 훨씬 크다. 따라서 재현율을 위해 정밀도를 일부 희생한 본 전략은 도메인 특성상 타당하다. 다만 제안 모델의 Accuracy(0.504)와 Precision(0.502)이 무작위 수준에 근접한다는 점은, 현재 모델이 대부분의 입력을 환각으로 판정하는 보수적 분류기에 가깝게 동작함을 의미한다. 즉 높은 재현율은 광범위한 환각 의심 판정의 결과이기도 하므로, 실용적 가치를 높이기 위해서는 정상 답변에 대한 오탐을 줄이는 정밀도 개선이 핵심 과제이다.

비교 분석 결과, 제안 모델은 SelfCheckGPT 대비 F1이 0.009, Recall이 0.088 향상되었다. MetaQA는 F1(0.784)과 Precision(0.775)이 가장 높았으나 Recall은 0.793에 그쳤다. 환각 누락을 최소화해야 하는 법률 도메인에서는, 비록 정밀도가 낮더라도 재현율이 압도적으로 높은 제안 모델이 더 적합하다. 이는 응용 도메인의 위험 구조에 따라 최적의 지표 균형이 달라짐을 보여준다.

5. 결론

본 논문은 법률 도메인 LLM 답변을 위한 3단계 환각 탐지 모델을 제안하였다. 제안 모델은 일관성 검사, NER 개체명

검증, NLI 모순 검사를 OR 규칙으로 결합하여 환각 누락을 최소화한다. 정상 400개와 환각 400개로 구성된 800개 법률 도메인 평가셋에서 제안 모델은 Recall 0.998, F1 0.668을 달성하여 SelfCheckGPT 대비 우수한 성능과 높은 안전성을 입증하였다.

제안 모델은 정상 답변에 대한 오탐이 많아 Precision이 0.502로 낮고, 매 질의마다 10개의 유사 질문과 11개의 답변을 생성해야 하므로 계산 비용이 크다는 한계가 있다. 향후 연구로는 임계값 최적화를 통한 Precision 향상, 두 단계 이상이 동시에 탐지할 때만 환각으로 판정하는 AND 조건이나 가중 투표(weighted voting) 기반 앙상블의 적용, 실시간 탐지 속도 개선, 그리고 다양한 법률 세부 도메인으로의 확장을 계획한다.

참고문헌

- [1] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su, Y. Xu, E. Ishii, Y. J. Bang, A. Madotto, P. Fung, "Survey of Hallucination in Natural Language Generation," ACM Computing Surveys, vol. 55, no. 12, Article 248, pp. 1–38, 2023.
- [2] I. Chalkidis, M. Fergadiotis, P. Malakasiotis, N. Aletras, I. Androutsopoulos, "LEGAL-BERT: The Muppets straight out of Law School," Findings of EMNLP 2020, pp. 2898–2904, 2020.
- [3] P. Manakul, A. Liusie, M. J. F. Gales, "SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models," Proc. EMNLP 2023, pp. 9004–9017, 2023.
- [4] J. Thorne, A. Vlachos, C. Christodoulopoulos, A. Mittal, "FEVER: a Large-scale Dataset for Fact Extraction and VERification," Proc. NAACL-HLT 2018, pp. 809–819, 2018.
- [5] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. Yih, T. Rocktäschel, S. Riedel, D. Kiela, "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," Advances in Neural Information Processing Systems, vol. 33, pp. 9459–9474, 2020.
- [6] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, Y. Artzi, "BERTScore: Evaluating Text Generation with BERT," Proc. ICLR 2020, 2020.
- [7] A. Conneau, R. Rinott, G. Lample, A. Williams, S. R. Bowman, H. Schwenk, V. Stoyanov, "XNLI: Evaluating Cross-lingual Sentence Representations," Proc. EMNLP 2018, pp. 2475–2485, 2018.
- [8] P. He, X. Liu, J. Gao, W. Chen, "DeBERTa: Decoding-enhanced BERT with Disentangled Attention," Proc. ICLR 2021, 2021.
- [9] B. Yang, M. A. Al Mamun, J. M. Zhang, G. Uddin, "Hallucination Detection in Large Language Models with Metamorphic Relations," Proceedings of the ACM on Software Engineering, vol. 2, no. FSE, 2025.